

Московский Государственный Технический Университет имени Н.Э.Баумана Факультет Информатика и системы управления

Кафедра ИУ-5 «Системы обработки информации и управления»

«Рубежный контроль №1»

«Методы машинного обучения»

Выполнили стулент группы ИУ5И- 23М Ся Тунтун

Вариант 17

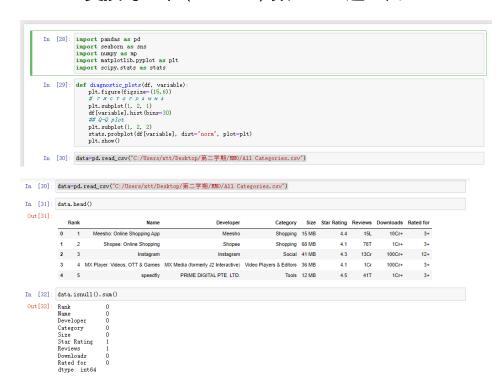
1. Задача №17.

Для набора данных проведите нормализацию для одного (произвольного) числового признака с использованием преобразования Йео-Джонсона (Yeo-Johnson transformation).

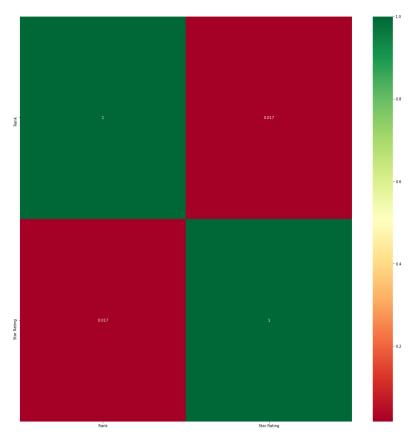
1. 任务#17。

对于一组数据,使用 Yeo-

Johnson 变换对一个(任意的)数字特征进行归一化。

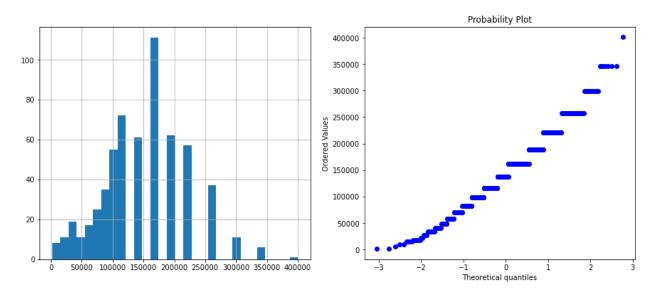


```
In [33]: data.info()
                  <class 'pandas.core.frame.DataFrame'>
RangeIndex: 600 entries, 0 to 599
Data columns (total 9 columns):
                  # Column
                                                   Non-Null Count Dtype
                   0 Rank
                                                   600 non-null
                                                   600 non-null
600 non-null
                                                                                object
object
                           Name
                           Developer
                                                   600 non-null
600 non-null
                          Category
Size
                                                                                object
object
                    3
                 5 Star Rating 599 non-null object
6 Reviews 599 non-null object
7 Downloads 600 non-null object
8 Rated for 600 non-null object
dtypes: float64(1), int64(1), object(7)
memory usage: 42.3+ KB
                                                                                float64
object
                                                                                 object
                                                                                object
In [34]: from sklearn.feature_selection import SelectKBest from matplotlib import pyplot as plt from sklearn.feature_selection import f_regression
In [35]: corrmat = data.corr()
                  top_corr_features = corrmat.index
plt.figure(figsize=(20,20))
                  #plot heat map
g=sns.heatmap(data[top_corr_features].corr(), annot=True, cmap="RdYIGn")
```



```
In [38]: #Необходимо преобразовать данные к действительному типу
data['Star Rating_yeojohnson'], param = stats.yeojohnson(data['Star Rating']) |
print('ОПТИМАЛЬНОЕ ЗНАЧЕНИЕ » = []'.format(param))
diagnostic_plots(data, 'Star Rating_yeojohnson')

ОПТИМАЛЬНОЕ ЗНАЧЕНИЕ » = 8.472135811722177
```



2. Задача №37.

Для набора данных проведите процедуру отбора признаков (feature selection) . Используйте класс SelectPercentile для 5% лучших признаков, и метод, основанный на взаимной информации.

2. 任务#37。

对于一个数据集,执行一个特征选择程序。对前 5% 的特征使用 SelectPercentile 类,并使用基于相互信息的方法。

```
In [50]: import numpy as np
           import pandas as pd
           import seaborn as sns
           import matplotlib, pyplot as plt
           from sklearn.datasets import load_iris
           from sklearn.datasets import load_boston
           import scipy.stats as stats
           from sklearn, sym import SVR
           from sklearn.svm import LinearSVC
           from sklearn.feature_selection import SelectFromModel
           from sklearn.linear_model import Lasso
           from sklearn.linear_model import LogisticRegression
          from sklearn.neighbors import KNeighborsClassifier
from sklearn.neighbors import KNeighborsRegressor
           from sklearn.tree import DecisionTreeClassifier
           from sklearn.ensemble import RandomForestClassifier
           from sklearn.ensemble import GradientBoostingClassifier
           from sklearn.tree import DecisionTreeRegressor
           from sklearn.ensemble import RandomForestRegressor
           from sklearn.ensemble import GradientBoostingRegressor
           from sklearn.metrics import mean_squared_error
           from sklearn.model_selection import train_test_split
           from sklearn.feature_selection import VarianceThreshold
           from sklearn feature_selection import mutual_info_classif, mutual_info_regression
           from sklearn.feature_selection import SelectKBest, SelectPercentile
           from IPython.display import Image
           Mmatplotlib inline
           sns. set(style="ticks")
```

```
In [51]: iris = load_iris()
    iris_X = iris.data
    iris_y = iris.target
    iris_feature_names = iris['feature_names']
    iris_x_df = pd. DataFrame(data=iris['data'], columns=iris['feature_names'])

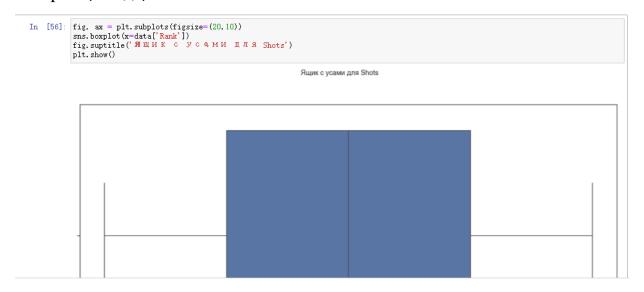
In [52]: boston = load_boston()
    boston_X = boston.data
    boston_y = boston.target
    boston_y = boston.target
    boston_feature_names = boston['feature_names']
    boston_x_df = pd. DataFrame(data=boston['data'], columns=boston['feature_names'])
```

Дополнительные требования по группам:

Для студентов групп ИУ5-23M, ИУ5И-23M - для произвольной колонки данных построить график "Ящик с усами (boxplot)".

各组的额外要求:

对于 IV5-23M、IV5I-23M 组的学生来说--对于任意一列数据建立一个图表 "boxplot(波谱)"。



Ящик с усами для Shots

